

Introduzione alla Fisica Statistica e alla Teoria dell'Informazione

X

Introduzione al corso: di che cosa si occupa la fisica statistica e la teoria dell'informazione, legame tra i due ambiti. Collegamenti con l'informatica: l'applicazione della teoria della probabilità alla computazione. Esempi motivanti.

X

1. Introduzione al corso

La *fisica statistica* si occupa dello studio delle proprietà di sistemi fisici con un *numero molto grande* di componenti, tra cui gli osservabili, le correlazioni, eccetera. Alcuni esempi di tali sistemi sono elettroni di un metallo, atomi di un gas, ma anche "*cose random*", agenti che si occupano di trading, elettori statunitensi ed eccetera...

La *teoria dell'informazione* va invece a studiare come comprimere e trasmettere in una maniera efficace l'*informazione*; ciò è importante per i nostri dispositivi digitali! Infatti, c'è spesso la necessità di trasmettere e di ricevere i dati.

I due campi (appunto la fisica statistica e la teoria dell'informazioni) erano paralleli fino a *Shannon* (1948), che evidenziò che l'entropia va usata per *quantificare l'informazione*. Essi sono comunque divisi, anche se profondamente legati; infatti, ad esempio, si usano simboli diversi per indicare le stesse quantità (come per l'entropia, nella fisica statistica si usa S e invece in teoria dell'informazioni si usa H)

Lo scopo di questo corso (e quindi di questi appunti) è quello di *capire l'entropia, come si calcola e come la applichiamo a problemi di varia natura tra cui l'ottimizzazione combinatoria*.

Un argomento *comune* è quello di applicare i risultati della *teoria della probabilità* all'*informatica* (computer science):

- Da un lato ciò richiede i formalismi della *fisica statistica*, in particolare per studiare i *sistemi disordinati e complessi*.
 - In particolare, è importante capire *quanto è difficile risolvere un problema*; ci sono problemi "*easy-to-solve*" e problemi "*hard-to-solve*"
- Vogliamo algoritmi che determinano un *risultato probabilistico*
- Vedremo dei cenni sugli *error-correcting codes*

Un esempio di collegamento è quello della *transizione di fase*, che in un certo senso è simile alla transizione di un problema "*easy-to-solve*" e "*hard-to-solve*".

Un esempio di problema di ottimizzazione combinatoria è la seguente.

NPP (Number Partitioning Problem)

Sia $L \subseteq \mathbb{Z}$ un sottoinsieme finito di interi, ovvero come ad esempio $L = \{1, 7, 12, 21, 43\}$. Il problema della "*Number Partitioning Problem*" consiste in trovare *due partizioni* $L = L_1 \sqcup L_2$ tali che le somme su L_1, L_2 siano uguali

Si dimostra che *NPP* è un problema "*easy-to-solve*" se e solo se $N/M > 1$, dove N è la lunghezza di L e M è il numero di bit necessari per rappresentare ogni numero della lista.

Il programma del corso si articolerà nei seguenti argomenti:

1. Variabili aleatorie ed entropia
2. Variabili indipendenti e correlate, ne quantificheremo l'entropia
3. Trasmissione e compressione dei dati; vedremo il *teorema di Shannon* (senza dimostrazione)
4. Distribuzione di Boltzmann e alcuni risultati principali della fisica statistica
5. Cenni al modello di Ising e come si applica
6. Ottimizzazione combinatoria e complessità computazionale
7. Esempi specifici di ottimizzazione combinatoria, tra cui NPP

Problema della Trasmissione dei Dati

X

Il problema della trasmissione dei dati. Inquadramento del problema, definizione di rate, encoder e decoder. Definizione di canali memoryless ed alcuni esempi. Definizione di capacità del canale, encoder e decoder, block error probability.

X


0. Voci correlate

- [Problema della Codifica dei Dati](#)
- [Richiami di Teoria della Probabilità per Fisica Statistica e Teoria dell'Informazione](#)

1. Trasmissione dei Dati

Sia m un messaggio generico a M bit da trasmettere su un canale, da cui "esce" m' la stima del messaggio m .

Tuttavia il canale presenta del *rumore* (dovuto a fattori interni, esterni, eccetera...), quindi diventa necessario passare m per un encoder $m \mapsto x$ con $N > M$ bit; quindi x passa per il canale da cui si ottiene x' e infine la passiamo per un decoder $x' \mapsto m'$.



Q. Sia $R = M/N$ il rate, qual è il valore massimo N ? Ossia, in che modo possiamo ricostruire il messaggio con probabilità d'errore che va verso zero usando meno bit aggiuntivi possibili?

N.B. Supponiamo che l'encoder e il decoder funzionino perfettamente, mi concentro solo sulle capacità del canale

X

2. Canali Memoryless e Capacità del Canale

Adesso formalizziamo il problema con un paio di definizioni

#Definizione

Definizione 1 (canale memoryless).

Il canale si dice *memoryless* se sbaglia "solo bit per bit". Ossia sia $\underline{x}$ il messaggio encoded e $\underline{y}$ l'output, allora la distribuzione di probabilità Q associata al canale è data da

$$Q(\underline{y}|\underline{x}) = \prod_{i=1}^N Q(y_i|x_i)$$

Notiamo che Q è la stessa per ogni i .


Alcuni esempi di canali memoryless sono come seguono:

- *Binary Symmetric*: Sia $x \in \{0, 1\}$ e sia $p \in [0, 1]$ fissato, allora Q consiste nella probabilità $1 - p$ di "non sbagliare" e p di "sbagliare". Ossia i bit vengono flippati con una certa probabilità p e la si definisce in formule come


$$Q(0|0) = Q(1|1) = 1 - p; Q(1|0) = Q(0|1) = p$$

- *Z-channel*: Sia $x \in \{0, 1\}$, ma solo uno dei due bit ha la probabilità di essere flippato e invece l'altra rimane sempre quella
- *Binary Erasure Channel*: Fissato $\varepsilon \in [0, 1]$, il canale "erasure" cancella il bit con probabilità ε .


Binary Symmetric



Z Channel



Binary Erasure



Adesso vediamo come quantificare il trattamento dei bit da parte del canale.

#Definizione

Definizione 2 (capacità del canale).

La capacità del canale è un numero in $[0, 1]$ definito come la massima mutual entropy tra X, Y che sono le variabili aleatorie di "input" e "output". In formule, ho

$$C := \max_{p(x)} I_{X,Y} = \max_{p(x)} \sum_{x,y} p(x,y) \log \frac{p(x,y)}{p(x)p(y)}$$

Notiamo che $p(x,y) = p(x)Q(y|x)$.

Se $C = 0$, allora il canale si dice "pure noise" in quanto non c'è nessuna sorta di correlazione tra l'input e output; se invece è $C = 1$, allora si dice "no noise". Infatti, in tal caso si avrebbe che $C = \max_{p(x)} H(p(x))$.

#Esempio

Esempio 3 (esempi di channel capacity).

In un canale binario simmetrico con flip probability p , si calcola la sua capacità come $C = 1 - H(p)$ dove $H(p)$ si riferisce all'entropia della distribuzione di Bernoulli avente parametro p .

X

3. Definizione di Encoder e Decoder

Adesso torniamo alle nozioni di *encoding* e *decoding*, vedendo bene come sono fatti X e Y .

#Definizione

Definizione 4 (encoding).

L'*encoder* è un mapping che manda $m \in \{0, 1\}^M$ in $x \in \{0, 1\}^N$, con $N \gg M$. Denotiamo il risultato del mapping con $\underline{x}(m)$ e si chiama *code word*. L'insieme dei possibili code word si dice *code book*.

Inoltre, dato l'encoding x si dice che i messaggi m sono "*N block length*".

Osservazione. Ci sono 2^M possibili code word a partire da 2^N messaggi originali. Nella fisica una trasformazione tra un insieme di cardinalità 2^N in 2^M noto come uno *spazio di Hamming*.

#Definizione

Definizione 5 (decoding).

Data la trasformazione sotto il canale dettato dalla distribuzione $Q(\underline{y}|\underline{x})$, il *decoder* è un mapping tra $\mathcal{Y}^N \rightarrow \{0, 1\}^M$ (notiamo che non è necessario che $\mathcal{Y} = \{0, 1\}$) e la denotiamo con $m' = d(\underline{y})$.

Alla fine tutto ci porta alla seguente definizione

#Definizione

Definizione 6 (error correcting code).

La coppia $(\underline{x}(m), d(\underline{y}))$ si dice *error correcting code*, ed è la parte più cruciale nella risoluzione del problema della trasmissione dei dati.

Dato l'error correcting code, si chiama $R = M/N$ il suo relativo *rate*.

X

4. Block Probability Error

Vediamo l'ultima nozione per quantificare l'errore commesso nel processo di encoding e decoding, *dovuto al rumore del canale*.

Definizione 7 (block probability error).

Sia $(\underline{x}, d)$ un error correcting code. La loro relativa *block probability error* è la probabilità che il messaggio in input differisca dal messaggio in output (ossia decodificato):

$$p_B(m) := \sum_{\underline{y}} Q(\underline{y}|\underline{x}(m)) \delta(d(\underline{y}) \neq m)$$

(N.B. δ è la delta di Kronecker)

#Definizione

Definizione 8 (misure relative alla block probability error).

In aggiunta, definiamo ulteriori misure relative alla block probability error:

Massima: $p_B^{\max} = \max_m p_B(m)$

Media: $\bar{p}_B = \frac{1}{2^M} \sum_m p_B(m)$

Catena di Markov Monte Carlo

X

Generalità sul metodo di Monte Carlo applicato alle catene di Markov. Idea: generare mosse "opportunamente" per avere una stima della distribuzione di probabilità. Le tre proprietà delle transmission rates: irriducibilità, aperiodicità e stazionarietà. Proprietà di bilancio dettagliato (o reversibilità). Teorema: limite della catena di Markov. Analisi dei tempi di convergenza.

X

0. Voci correlate

- [Richiami di Teoria della Probabilità per Fisica Statistica e Teoria dell'Informazione](#)

1. Catene di Markov: Approfondimenti

Sia $(X_t)_t$ una sequenza di variabili aleatorie. Allora si ha che è una *catena di Markov* se esiste $W(x \rightarrow y)$ tale che $\sum_{y \in \mathcal{X}} W(x \rightarrow y) = 1$ e che

$$p_N(x_1, \dots, x_N) = p_1(x_1) \prod_{t=0}^{N-1} W(x_t \rightarrow x_{t+1})$$

Notiamo che la markovianità della definizione (1) discende dal fatto che le probabilità dipendono *solamente* dall'ultima transizione.

Definiamo una serie di proprietà "*desiderabili*" su una catena di Markov, che in particolare va a caratterizzare W .

#Proposizione

Proposizione 1 (alcune proprietà di W).

Sia W una set di *transition rates*. Allora si dice che è:

1. *Irriducibile* sse vale che per ogni due stati posso in un qualche modo congiungerli:

$$\forall x, y \in \mathcal{X}, \exists (x_0, \dots, x_N) : x_0 = x, x_N = y, \forall i, W(x_i \rightarrow x_{i+1}) > 0$$

2. *Aperiodica* sse posso sempre per ogni due stati non esiste un "*massimo*" numero di step possibili per poter congiungerli

$$\forall x, y \in \mathcal{X}, \exists N = N(x, y) : \forall n \geq N, \exists (x, \dots, y) : p(x, \dots, y) > 0$$

3. $p(x)$ si dice *stazionaria* rispetto a W sse vale che

$$\sum_y p(x)W(x \rightarrow y) = p(y)$$

4. Una condizione più forte che implica la stazionarietà è il *bilancio dettagliato* o la *reversibilità*:

$$p(x)W(x \rightarrow y) = p(y)W(y \rightarrow x)$$

X

2. Monte Carlo Markov Chain

Problema. Voglio stimare la distribuzione di probabilità di un sistema fisico probabilistico.

Idea. Ricordandomi il principio delle large deviations, per cui ho $\mathcal{N}$ "configurazioni tipiche", vorrei generare una catena di Markov che converga a $p(x)$ in una maniera "intelligente". Il seguente teorema pone le basi per il *metodo di Monte Carlo Markov Chain*:

Teorema 2 (MCMC).

Supponiamo che la catena di Markov con $W(x \rightarrow y)$ soddisfi le proprietà di irriducibilità, aperiodicità e di stazionarietà. Siano $x_1, \dots, x_t, \dots$ degli stati generate con la rete di transizioni W . Sia $f : \mathcal{X}^N \rightarrow \mathbb{N}$ la funzione di cui voglio fare una *stima* della media.

Allora si hanno i seguenti limiti:

$$\begin{aligned} i) \quad & \lim_t p(X_t = x) = p(x) \\ ii) \quad & \lim_t \frac{1}{t} \sum_{s=1, \dots, t} f(x_s) = \sum_x p(x) f(x) = \mathbb{E}[f(X)] \end{aligned}$$

In pratica il limite ii) ci dice che la media empirica tende ad una vera media! L'unico "*caveat*" è che non si conosce il tempo t_∞ per cui si raggiunge una convergenza "soddisfacente".

X

3. Tempi di Convergenza

Abbiamo più modi per stimare i *tempi di convergenza*.

3.1. Convergenza i)

Per stimare la convergenza del limite i) del teorema fondamentale ([Teorema 2](#)), definiamo la distanza tra distribuzioni di probabilità con la *variation distance*:

$$\|p_1 - p_2\| = \frac{1}{2} \sum_{\underline{x}} |p_1(\underline{x}) - p_2(\underline{x})|$$

Applicando alle MCMC, da $\underline{x}_0$ abbiamo la probabilità condizionale $p_t(\underline{x}_t | \underline{x}_0)$ da cui possiamo calcolare la distanza della probabilità stimata al passo t -esimo da quello vero:

$$d_{\underline{x}_0}(t) := \|p_t(\bullet | \underline{x}_0) - p(\bullet)\|$$

Adesso definiamo il tempo di equilibrizzazione rispetto ad una soglia ε come

$$t_{\text{eq}}(\varepsilon) := \min\{t \geq 0 : \sup_{\underline{x}_0} d_{\underline{x}_0}(t) \leq \varepsilon\}$$

3.2. Convergenza ii)

Invece per il limite ii), vogliamo calcolare l'osservabile $\mathcal{O}$. A questo punto potrei definire la media empirica al tempo T come

$$\bar{\mathcal{O}}_T := \frac{1}{T} \sum_{t=0}^T \mathcal{O}(\underline{x}_t)$$

In più definiamo la varianza per capire la possibile "fascia d'errore":

$$\text{Var}(\bar{\mathcal{O}}_T) := \frac{1}{T^2} \sum_{s,T=0}^{T-1} \langle \mathcal{O}_s, \mathcal{O}_T \rangle = \frac{1}{T^2} \sum_{t=0}^{T-1} \langle \mathcal{O}_0, \mathcal{O}_T \rangle$$

Definiamo l'autocorrelazione come

$$C_{\mathcal{O}}(t-s) = \frac{\langle \mathcal{O}_s, \mathcal{O}_t \rangle}{\langle \mathcal{O}_0, \mathcal{O}_0 \rangle}$$

Da cui posso riscrivere la varianza come

$$\text{Var}(\bar{\mathcal{O}}_T) = \frac{\langle \mathcal{O}_0, \mathcal{O}_0 \rangle}{T^2} \sum_{t=0}^{T-1} (T-t) C_{\mathcal{O}}(t)$$

La parte cruciale di questa formula è che $C_{\mathcal{O}}$ decresce *esponenzialmente*, convergendo verso al tempo caratteristico di autocorrelazione $\tau_{\text{int}}^{\mathcal{O}}$. Quindi si dimostra che

$$\text{Var}(\bar{\mathcal{O}}_T) = \frac{\tau_{\text{int}}^{\mathcal{O}}}{T} [\mathbb{E}_p[\mathcal{O}^2] - (\mathbb{E}_p[\mathcal{O}])^2] + O(T^{-2})$$

Ossia, si considera di aver raggiunto una "buona media" per $t \geq \tau_{\text{int}}^{\mathcal{O}}$, dato dalla sommatoria $\sum_t C_{\mathcal{O}}(t)$.

Inoltre, la formula (2) ci dice anche che per ogni $\tau_{\text{int}}^{\mathcal{O}}$ configurazioni ottengo una stima statisticamente indipendente.

Problema QUBO

X

Formulazione di problema QUBO. Mappatura di alcuni problemi dell'ottimizzazione combinatoria a problemi QUBO: NPP e max-cut.

X

0. Voci correlate

- [Problemi Combinatori Noti](#)
- [Modello di Ising su una retta unidimensionale](#)
- [Number Partitioning Problem](#)
- <https://doi.org/10.1007/s10479-022-04634-2>

1. Problema QUBO

#Definizione

Definizione 1 (QUBO).

Il problema "*Quadratic Unconstrained Binary Optimization*" (QUBO) consiste in ottimizzare la forma quadratica

$$y = \mathbf{x}^T Q \mathbf{x}$$

Dove $\mathbf{x}$ è un vettore *booleano* (quindi in $\{0, 1\}^N$) e si chiama il *vettore delle decisioni*, invece $Q \in \mathbb{R}^{n \times n}$ è una matrice simmetrica.

La funzione obbiettivo è esprimibile come una sommatoria:

$$y = \sum_{i,j} x_i Q_{ij} x_j$$

Il problema non è facile! Infatti, stiamo minimizzando su $x_i, x_j = 0, 1$ e non in $\mathbb{R}$.

X

2. Mappatura di Problemi a QUBO

Molti problemi dell'ottimizzazione combinatoria possono essere mappati in problemi QUBO. Vedremo alcuni esempi significativi

2.1. NPP

Supponiamo di voler risolvere la number partitioning problem su $S = \{S_1, \dots, S_n\} \subset \mathbb{Z}$.

Per mapparla in un problema QUBO, possiamo definire $x_i \in \{0, 1\}$, che assume uno dei due valori a seconda della collocazione del valore S_i .

Rimane solo da trasformare la funzione obbiettivo. Otteniamo le *quantità di somma sulle singole partizioni*, date da

$$\begin{aligned}\text{SUM}_1 &:= \sum_j S_j x_j \\ \text{SUM}_2 &:= \sum_j S_j (1 - x_j)\end{aligned}$$

Da cui otteniamo la differenza

$$\text{DIFF} := \text{SUM}_1 - \text{SUM}_2 = C - 2 \sum_j S_j x_j$$

Dove C è una costante trascurabile in un problema di ottimizzazione. Eleviamo la differenza al quadrato, ottenendo

$$\begin{aligned}\text{DIFF}^2 &= \left(C - 2 \sum_j x_j S_j \right)^2 \\ &= C^2 + 4 \sum_{i,j} x_i x_j S_i S_j - 4C \sum_j x_j S_j \\ &= C^2 + 4 \sum_{i,j} [S_i S_j x_i x_j - C S_j x_j]\end{aligned}$$

Notiamo che $x_j = 0, 1$, e quindi $x_j = x_j^2$. Pertanto otteniamo che

$$\text{DIFF}^2 \propto \sum_{i,j} [S_i S_j x_i x_j - C S_j x_j^2]$$

Pertanto possiamo riscriverlo come una forma quadratica del tipo $\mathbf{x}^T Q \mathbf{x}$, dove Q_{ij} è definito come segue:

$$Q_{ij} = \begin{cases} S_i S_j, & i \neq j \\ S_i (S_i - C), & i = j \end{cases}$$

Concludendo la mappatura

Esempio. Considerare NPP sul set $S = \{25, 7, 13, 31, 42, 17, 21, 10\}$. Allora mappandolo in QUBO otteniamo $C^2 = 27556$ e risolvendolo otteniamo la soluzione

$$\mathbf{x} = (0 \ 0 \ 0 \ 1 \ 1 \ 0 \ 0 \ 1)^T$$

Da notare che abbiamo anche le due partizioni gratis!

2.2. Max-Cut

Dato un grafo non orientato e non pesato $G = (V, E)$, vogliamo bi-partizionare V in un modo tale che il numero di archi che uniscono le due partizioni sia *massimo*.

Per rappresentare il problema con *variabili booleane*, poniamo

$$x_i := \begin{cases} 0, & i \in A \subseteq V \\ 1, & i \in V \setminus A \end{cases}$$


Dove A è la partizione che stiamo "costruendo". Per calcolare il *numero di archi che collegano le due partizioni*, abbiamo la seguente formula:

$$n = \sum_{(i,j) \in E} x_i + x_j - 2x_i x_j$$

In un certo senso, abbiamo trasformato la formula booleana $\neg(x_i \wedge x_j) \wedge (x_i \vee x_j)$ in un'espressione aritmetica.

2.3. Minimum Vertex Cover

Dato $G = (V, E)$, definiamo un *vertex cover* come un sottoinsieme dei vertici tale che ogni arco collegato ad un qualunque vertice del sottoinsieme collega tutto V



Si dimostra che è riconducibile al problema di QUBO.

2.4. Modello di Ising

Per ultimo, vediamo come il *modello di Ising* sia collegato al problema QUBO. Infatti, notiamo subito che entrambi i problemi hanno una natura "*binaria*" in termini di scelte.

L'unica differenza sono le quantità da minimizzare:

- In QUBO ho $y = \sum x_i Q_{ij} x_j$

- In Ising ho l'Hamiltoniana $E(\{S_i = \pm 1\})$

Li colleghiamo definendo x_i come la "normalizzazione" delle variabili di Ising, ossia

$$x_i = \frac{S_i + 1}{2}$$

In questo modo possiamo trasformare la funzione obbiettivo di QUBO nell'Hamiltoniana di Ising. In particolare, assumendo il caso generale $E = -\sum_{i,j} J_{ij} S_i S_j - \sum_i S_i h_i$, abbiamo che y diventa

$$\begin{aligned} y &= \sum_{i,j} \frac{1 + S_i}{2} Q_{ij} \frac{1 + S_j}{2} \\ &= C + \sum_{i,j} \frac{Q_{ij}}{4} S_i S_j + \frac{1}{4} \sum_{i,j} S_j Q_{ij} + \frac{1}{4} \sum_{i,j} S_i Q_{ij} \end{aligned}$$

Quindi otteniamo le seguenti corrispondenze:

$$J_{ij} = -\frac{Q_{ij}}{4}, h_i = \frac{1}{2} \sum_j Q_{ij}$$

Concludendo. ■

Esercizi sull'Ottimizzazione Combinatoria

X


Esercizi di ottimizzazione combinatoria

X

1. Esercizi Combinatoria

Esercizio 1 (MST, 1).

Trovare la soluzione al seguente problema MST:



Costo minimo: 12

soluzione

Esercizio 2 (MST, 2).

Considerare l'MST precedente ma abbiamo un peso negativo. Cambia qualcosa?

No, siccome possiamo aggiungere delle costanti e risolvere il problema nello stesso modo

soluzione

Esercizio 3 (NPP).

Considerare il problema NPP col seguente set:

$$S = \{10, 13, 23, 6, 20\}$$

Risolverlo con l'algoritmo greedy e di K-K.

traccia

Greedy: scegliere, alternando i basket: 23, 20, 13 e 10. Alla fine notare che tra due basket c'è una discrepanza di 6, che è proprio il valore dell'ultimo item rimasto e quindi inserire questo elemento opportunamente

K-K: Alla fine otteniamo l'insieme vuoto, quindi c'è una soluzione ottimale

Esercizio 4 (NPP, primi).

Il problema di NPP con S i primi 101 numeri primi è *easy to solve* o *hard to solve*? Notare che si osservò che $\pi(n) \sim \frac{n}{\log n}$, dove $\pi(n)$ è il numero di numeri primi prima di n .

Easy to solve, siccome $\frac{n}{\log n} \gg 1$.

soluzione

Esercizio 5 (QUBO rephrasing).

Data la funzione obiettivo

$y = -5x_1 - 3x_2 - 8x_3 - 6x_4 - 4x_1x_2 + 8x_1x_3 + 2x_2x_3 + 10x_3x_5$, riscriverlo in forma

$y = x^T Q x$.


Si ha che $E = \{(1, 2), (1, 3), (2, 5), (3, 4), (3, 5)\}$ e quindi usando la formula per il numero di vertici interessati si ottiene un'espressione del tipo

$$y = (x_1 + x_2 - 2x_1x_2) + \dots$$

Per trasformarlo in una forma del tipo $y = x^T Q x$, si conta il numero di volte che appaiono i termini $x_i x_j$. Quindi otteniamo

$$Q = \begin{pmatrix} 2 & -1 & -1 & 0 & 0 \\ 2 & 0 & -1 & 0 & 0 \\ -1 & -1 & 2 & -1 & -1 \\ 3 & -1 & -1 & 2 & -1 \\ 2 & 0 & -1 & -1 & 2 \end{pmatrix}$$

N.B. negli spazi vuoti abbiamo il suo corrispondente valore simmetrico, li ho lasciati vuoti per pigritia



Considerare il problema max-cut sul seguente grafo e mapparlo in un problema QUBO:

Esercizio 6 (max-cut to QUBO).

Osservare che $x^T Q x = \sum_{i,j} Q_{ij} x_i x_j$, quindi riportare i valori dimezzandole siccome vengono contati due volte (tranne la diagonale principale). Quindi Q diventa

$$Q = \begin{pmatrix} -5 & 2 & -3 & 4 & 0 \\ 2 & 1 & -8 & 5 & -6 \\ -3 & 1 & 0 & -8 & 5 \\ 4 & 5 & -8 & 1 & 0 \\ 0 & 0 & 5 & 0 & -6 \end{pmatrix}$$